

PlaylistPro 인공지능 모델 학습 결과서

작성일: 2026-07-22

최종 기술 모델: CatBoost

완료 Run: 20260721_full_fair_v1

1. 문제 유형과 선정 원칙

churned(0=유지, 1=이탈)를 예측하는 이진 분류 문제입니다. 이탈 고객을 놓치는 FN과 불필요한 접촉을 만드는 FP를 함께 관리해야 하므로 다음 순서로 판단했습니다.

- 모델 순위 품질: PR-AUC
- 내부 일반화: 고정 5-Fold OOF
- 운영 Guardrail: Recall, Precision, F1, FN, FP, 대상 고객 수
- 안정성: 5개 Seed와 1,000회 Bootstrap
- 확률 품질: Brier와 Calibration
- 재현성: 저장 Pipeline 재로딩·스키마 테스트

Accuracy 단독으로 모델을 선정하지 않았고, Threshold는 모델 선택과 분리했습니다.

2. 데이터 분할과 비교 조건

항목	설정
데이터	Train 125,000명, Test 75,000명(무라벨)
비교 Fold	고정 Stratified 5-Fold
Random State	42
공통 Feature	log_numeric
전처리	각 학습 Fold 내부 Pipeline Fit
1차 지표	PR-AUC
외부 라벨 Holdout	없음

모든 8개 모델은 저장된 동일 Fold와 동일 Feature를 사용했습니다. 제공 Test는 추론에만 사용했으며 모델·파라미터·Threshold 선택에 사용하지 않았습니다.

3. Baseline과 후보 모델


모델	포함 이유
DummyClassifier	학습 모델이 넘어야 할 양성 비율 기준선
Logistic Regression	해석 가능한 선형 기준선과 전처리 검증기

모델	포함 이유
Decision Tree	단순 비선형 규칙 기준
Random Forest	Bagging 기반 상호작용 비교
Gradient Boosting	순차 Boosting 기준
XGBoost	규제-병렬 Tree Boosting 후보
LightGBM	빠른 Histogram Boosting과 높은 Recall 후보
CatBoost	범주형-비선형 관계에 강한 Boosting 후보

MLP·딥러닝은 일반 정형 합성 데이터에서 발표 가치 대비 비용이 낮고, 강한 Boosting 기준선이 이미 있어 의도적으로 제외했습니다.

4. 전처리 기반 성능 개선


Raw Logistic OOF PR-AUC 0.899495에서 비율 Feature와 로그 변환을 결합한 log_numeric Logistic 0.906293으로 +0.006798 개선했습니다. 비율만 추가한 단독 변형과 signal-pruned 변형은 개선하지 못해 제외했습니다. 최종 log_numeric Pipeline에는 네 가지 완화 비율과 로그 변환이 함께 남아 있습니다. Tree 검증에서 log_numeric의 Raw 대비 차이는 +0.000089로 작으므로, 공통 Feature의 일관성을 위한 선택이지 전체 성능 향상의 유일 원인으로 주장하지 않습니다.



5. 8개 모델 동일 조건 비교

모델	PR-AUC	ROC-AUC	F1	Recall	Precision	Brier	학습 초
CatBoost	0.947622	0.941700	0.847008	0.824181	0.871136	0.095612	15.8
LightGBM	0.947534	0.941629	0.852983	0.867345	0.839089	0.095306	12.2
XGBoost	0.947052	0.941105	0.850891	0.845249	0.856608	0.101813	10.1
Gradient Boosting	0.946362	0.940415	0.851252	0.852432	0.850075	0.102189	344.9

모델	PR-AUC	ROC-AUC	F1	Recall	Precision	Brier	학습 초
Random Forest	0.939448	0.934125	0.850400	0.853461	0.847361	0.108169	26.2
Decision Tree	0.936079	0.933386	0.846347	0.851794	0.840969	0.102677	10.9
Logistic	0.906293	0.897232	0.811807	0.809954	0.813669	0.130653	3.7
Dummy	0.513386	0.499987	0.678465	1.000000	0.513392	0.249821	2.5



8개 모델 비교

CatBoost의 PR-AUC가 가장 높고 LightGBM은 기본 Threshold에서 F1·Recall·Brier가 더 좋습니다. 이 Trade-off 때문에 단일 지표만으로 운영 정책을 확정하지 않았습니다.

6. 하이퍼파라미터 탐색


6.1 제한된 RandomizedSearch

모델	Trial	유효 Trial	최선 CV PR-AUC
Logistic	20	20	0.906304
Decision Tree	20	20	0.935717
Random Forest	24	24	0.942988
Gradient Boosting	24	24	0.947974
XGBoost	30	30	0.947856
LightGBM	30	30	0.947743
CatBoost	24	24	0.948016

Random Forest와 Gradient Boosting은 사용자 요청에 따라 탐색 범위를 경량화했지만 모델을 제외하지 않았습니다. 완료된 Checkpoint를 재사용했고 제출 문서 생성 중 재학습하지 않았습니다.

6.2 실제 상위 3개 Fine Tuning


모델	Trial	Fine CV PR-AUC	OOF PR-AUC	F1	Recall	Precision
CatBoost	15	0.947913	0.947897	0.849118	0.836382	0.862247
LightGBM	15	0.947806	0.947790	0.851892	0.859850	0.844079
XGBoost	15	0.947793	0.947765	0.850378	0.844283	0.856562



7. 최종 CatBoost 선정 근거

판단 기준	CatBoost	XGBoost	LightGBM	해석
Fine CV PR-AUC	0.947913	0.947793	0.947806	사전 1차 기준 1위
OOF PR-AUC	0.947897	0.947765	0.947790	순위 품질 근소한 1위
5-Seed 평균 PR-AUC	0.947880	0.947726	0.947721	Seed 평균 1위
5-Seed 표준편차	0.000061	0.000061	0.000095	모두 안정적
Brier	0.095215	0.095383	0.095049	LightGBM 소폭 우위
평균 Calibration gap	0.01454	0.01899	0.01250	LightGBM 소폭 우위


CatBoost를 기술 후보로 선택한 이유는 Fine CV-OOF-Seed 평균 PR-AUC가 일관되게 근소한 1위이기 때문입니다. 그러나 Bootstrap 95% 구간이 겹치며, LightGBM은 기본 Threshold의 Recall·F1과 확률 보정에서 소폭 우위입니다. 따라서 “CatBoost가 모든 기준에서 압도적으로 최고”라고 주장하지 않습니다.



8. Threshold와 운영 오류


8.1 기본 Threshold 0.50

PR-AUC	ROC-AUC	F1	Recall	Precision	TP	TN	FN	FP
0.947897	0.941959	0.849118	0.836382	0.862247	53,674	52,251	10,500	8,575




8.2 운영 선택지

시나리오	Threshold	대상	Recall	Precision	F1	FN	FP
재현율 우선	0.29	77,700	0.9518	0.7861	0.8611	3,091	16,617
균형형 F1	0.35	76,143	0.9444	0.7959	0.8638	3,569	15,538
정밀도 우선	0.74	48,463	0.7180	0.9507	0.8181	18,099	2,388



Threshold 지표





Threshold 대상과 오류

기본 화면값 0.35는 OOF F1이 높은 선택지일 뿐 사업 확정값이 아닙니다. Recall 우선 여부, 접촉 가능 인원 및 FN·FP 비용이 바뀌면 다른 Threshold나 LightGBM이 선택될 수 있습니다.

9. Top-K, Lift와 Risk Decile

Top K	대상 고객	포착 이탈 고객	Capture	Precision	Lift
5%	6,250	6,250	9.74%	100.00%	1.948
10%	12,500	12,500	19.48%	100.00%	1.948
20%	25,000	24,996	38.95%	99.98%	1.948
30%	37,500	36,457	56.81%	97.22%	1.894
40%	50,000	47,158	73.48%	94.32%	1.837






이 값은 OOF 순위 진단입니다. 캠페인 Uplift나 실제 접촉 효과가 아닙니다. 합성 규칙이 위험 순위를 강하게 분리해 Top 10% Precision 100%가 나타났으므로 실서비스 기대치로 사용하면 안 됩니다.

10. 오류·세그먼트 분석


세그먼트	고객	관측 이탈률	PR-AUC	Recall	Precision	FN	FP
Family	31,072	34.58%	0.8893	0.7488	0.7929	2,699	2,101
Free	31,269	79.41%	0.9827	0.9271	0.9158	1,810	2,117
Premium	31,354	33.91%	0.8793	0.7238	0.7923	2,937	2,017
Student	31,305	57.39%	0.9461	0.8300	0.8644	3,054	2,340



Premium·Family의 Recall이 낮아 일률적인 전체 지표만으로 운영하면 놓치는 고객군이 달라질 수 있습니다. 다만 합성 데이터의 세그먼트 차이이며 실제 공정성 평가를 대신하지 않습니다.

11. 모델 해석

상위 중요 Feature는 Free 요금제, 문의 수준, log1p_weekly_hours, 나이, 일시정지 횟수, 청취시간, 스킵률입니다.



Feature Importance는 모델이 예측에 사용한 정도이며 이탤의 인과 원인이 아닙니다. 나이·지역은 직접 행동 신호에서 제외하고 문의·청취시간·스킵·일시정지·구독 유형만 투명한 유지 전략 규칙에 사용합니다. 다만 나이·지역은 예측 모델 입력이므로 위험 점수와 캠페인 단계에 간접 영향을 줄 수 있으며, 운영 적용 전 공정성 검토가 필요합니다.

12. 저장 모델과 재현성

항목	결과
모델 파일	models/churn_pipeline.joblib
SHA-256	fc35ca91e9242dbc0e914db9f0dfc9e994024a5d4cc8d0d770d12321989a7d0e
새 프로세스 재로딩	통과
신규 한 행 예측	통과
열 순서 변경	허용
미등록 범주	허용
필수 열 누락	거부
잘못된 수치 자료형	거부
Streamlit 재학습	없음

모델과 함께 artifacts/feature_schema.json, artifacts/model_metadata.json, artifacts/metrics.csv를 제출합니다.

13. 한계와 최종 판단

- 독립된 외부 라벨 Holdout이 없어 외부 일반화를 검증하지 못했습니다.

- 예측 시점과 결과 기간이 없어 시간 기반 검증이 필요합니다.
- 규칙 기반 합성 데이터의 높은 성능은 실제 서비스 기대치가 아닙니다.
- OOF Threshold는 운영 Trade-off 참고값이며 독립 성능이 아닙니다.
- 유지 행동의 Uplift·ROI는 실제 A/B 테스트와 미래 라벨이 필요합니다.
- 실제 운영 모델 승인, Threshold 선택, 데이터 권리 및 배포는 사용자·조직의 결정입니다.

현재 증거에서 CatBoost는 PR-AUC 우선 목표에 가장 부합하는 권고 기술 후보입니다. Recall·FN 최소화가 절대 우선이면 LightGBM 또는 CatBoost의 더 낮은 Threshold를 함께 검토해야 합니다.

14. 재현 파일

- notebooks/03_model_experiments.ipynb
- artifacts/model_comparison_fair.csv
- artifacts/random_search_summary.csv
- artifacts/top3_fine_tuning_summary.csv
- artifacts/bootstrap_confidence_intervals.csv
- artifacts/threshold_operating_scenarios_v2.csv
- artifacts/topk_lift_oof_catboost.csv
- artifacts/risk_decile_oof_catboost.csv
- artifacts/metrics.csv
- figures/training/